

# 基于 DBN 模型的遥感图像分类

吕 启<sup>1</sup> 窦 勇<sup>1</sup> 牛 新<sup>1</sup> 徐佳庆<sup>1</sup> 夏 飞<sup>2</sup>

<sup>1</sup>(国防科学技术大学计算机学院并行与分布处理国防科技重点实验室 长沙 410073)

<sup>2</sup>(海军工程大学电子工程学院 武汉 430033)

(lvqi@nudt.edu.cn)

## Remote Sensing Image Classification Based on DBN Model

Lü Qi<sup>1</sup>, Dou Yong<sup>1</sup>, Niu Xin<sup>1</sup>, Xu Jiaqing<sup>1</sup>, and Xia Fei<sup>2</sup>

<sup>1</sup>(National Laboratory for Parallel and Distributed Processing, School of Computer, National University of Defense Technology, Changsha 410073)

<sup>2</sup>(Electronic Engineering College, Naval University of Engineering, Wuhan 430033)

**Abstract** Remote sensing image classification is one of the key technologies in geographic information system (GIS), and it plays an important role in modern urban planning and management. In the field of machine learning, deep learning is springing up in recent years. By mimicking the hierarchical structure of human brain, deep learning can extract features from lower level to higher level gradually, and distill the spatio-temporal regularizes of input data, thus improve the classification performance. Deep belief network (DBN) is a widely investigated and deployed deep learning model. It combines the advantages of unsupervised and supervised learning, and can archive good classification performance for high-dimensional data. In this paper, a remote sensing image classification method based on DBN model is proposed. This is one of the first attempts to apply deep learning approach to urban detailed classification. Six-day high-resolution RADARSAT-2 polarimetric synthetic aperture radar (SAR) data were used for evaluation. Experimental results show that the proposed method can outperform SVM (support vector machine) and traditional neural network (NN).

**Key words** remote sensing image; synthetic aperture radar(SAR); land cover classification; deep learning; restricted Boltzmann machine (RBM); deep belief network (DBN)

**摘要** 遥感图像分类是地理信息系统(geographic information system, GIS)的关键技术,对城市规划与管理起到十分重要的作用。近年来,深度学习成为机器学习领域的一个新兴研究方向。深度学习采用模拟人脑多层结构的方式,对数据从低层到高层渐进地进行特征提取,从而发掘数据在时间与空间上的规律,进而提高分类的准确性。深度信念网络(deep belief network, DBN)是一种得到广泛研究与应用的深度学习模型,它结合了无监督学习和有监督学习的优点,对高维数据具有较好的分类能力。提出一种基于 DBN 模型的遥感图像分类方法,并利用 RADARSAT-2 卫星 6 d 的极化合成孔径雷达(synthetic aperture radar, SAR)图像进行了验证。实验表明,与支持向量机(SVM)及传统的神经网络(NN)方法相比,基于 DBN 模型的方法可以取得更好的分类效果。

收稿日期:2014-03-09;修回日期:2014-06-04

基金项目:国家自然科学基金项目(61125201,61202127)

通信作者:吕 启(lvqi@nudt.edu.cn)

**关键词** 遥感图像;合成孔径雷达;地物分类;深度学习;受限玻尔兹曼机;深度信念网络

**中图法分类号** TP391; TP751

遥感图像分类是指把遥感图像中的每个像元划归到类别中的过程,是模式识别技术在遥感领域的具体运用,也是地理信息系统(geographic information system, GIS)的关键技术。其主要用途是根据地物电磁波辐射在遥感图像上的特征,判读识别地面物体的类属。分类图既可作为中间结果为目标检测与识别等其他应用提供辅助信息,也可作为最终结果提供基础地理信息用于地图测绘、城市规划、资源监管、环境保护、救灾抢险、军事侦察等领域。

和光学成像传感器相比,合成孔径雷达(synthetic aperture radar, SAR)不会受到光照和气候条件的影响,具有全天时全天候工作的特点,因此被广泛应用于遥感领域<sup>[1]</sup>。同时,由于极化分解可以获得更多的相关信息,极化 SAR(polarimetric SAR, PolSAR)被越来越多地应用于遥感图像分类<sup>[2]</sup>。

根据是否需要数据的先验知识,遥感分类方法可以划分为参数化(parametric)方法和非参数化(non-parametric)方法两类。参数化方法包括最小距离分类器(minimum distance classifier, MDC)<sup>[3]</sup>、极大似然分类器(maximum likelihood classifier, MLC)<sup>[4]</sup>和期望最大(Expectation-Maximization, EM)算法<sup>[5]</sup>,它们需要对数据分布有预先的假设。然而,对于多时与多源的遥感数据,数据分布规律往往难以知道。因此,非参数方法被更广泛地用于遥感图像分类,包括人工神经网络(artificial neural network, ANN)<sup>[6]</sup>、决策树<sup>[7]</sup>、支持向量机(support vector machine, SVM)<sup>[8-10]</sup>等。

2006年,多伦多大学机器学习领域的著名教授Hinton和他的学生Salakhutdinov在国际顶尖学术期刊《Science》上发表一篇文章<sup>[11]</sup>,提出利用深度信念网络(deep belief network, DBN)实现数据的降维及分类,引发了深度学习(deep learning)的浪潮。自此以后,深度学习作为机器学习的一个新兴研究方向,受到了学术界和工业界的极大关注<sup>[12-19]</sup>。深度神经网络采用模拟人脑多层结构的方式,对输入数据从低层到高层渐进地进行特征提取,最终形成适合模式分类的较理想特征,从而提升分类或者预测的准确性。近几年,深度学习技术在图像识别、语音识别、自然语言处理、信息检索等领域取得了巨大成

功<sup>[12,17,19]</sup>。文献[20]提出用DBN模型对机载遥感图像中的道路进行检测,这是深度学习方法被首次用于遥感领域。然而,到目前为止尚未发现有将深度学习模型应用于SAR遥感图像分类的相关工作。

本文提出一种基于DBN模型的遥感图像分类方法,并利用多天的RADARSAT-2卫星极化SAR图像进行了验证。实验结果表明,与SVM等方法相比,基于DBN模型的方法可以取得更好的分类效果。

## 1 DBN 模型简介

深度信念网络由Hinton等人<sup>[21]</sup>于2006年提出,作为一种深度学习模型受到了广泛关注,并被成功应用在物体识别、语音识别等领域。从结构上看, DBN由多层无监督的受限玻尔兹曼机(restricted Boltzmann machine, RBM)网络和一层有监督的反向传播(back-propagation, BP)网络组成,如图1所示:

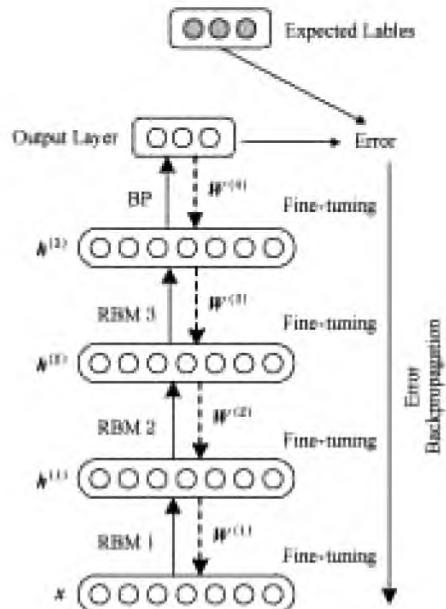


Fig. 1 Schematic diagram of DBN.

图1 DBN示意图

DBN的训练包含“预训练(pre-training)”和“微调(fine-tuning)”2个步骤。pre-training阶段DBN采用逐层(layerwise)训练的方式对各层中的RBM

进行训练,低一层 RBM 的隐含层输出作为上一层的 RBM 的可见层输入, fine-tuning 阶段采用有监督学习方式对最后一层的 BP 网络进行训练,并将实际输出与预期输出的误差逐层向后传播,对整个 DBN 网络的权值进行微调。RBM 网络的训练过程实际上可看成是对深层 BP 网络权值的初始化,使 DBN 克服了 BP 网络因随机初始化权值参数而导致的训练时间长和容易陷入局部最优解的缺点。

### 1.1 受限玻尔兹曼机

受限玻尔兹曼机是一种典型的基于能量的模型 (energy-based model, EBM), 它由一个可见层 (visible layer) 与一个隐含层 (hidden layer) 组成, 如图 2 所示。其中,  $v$  和  $h$  分别表示可见层与隐含层,  $W$  表示两层之间的连接权值。对于可见层与隐含层, 其连接关系为层间神经元全连接, 而层内没有神经元相连。

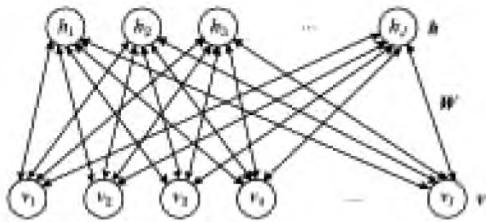


Fig. 2 Schematic diagram of RBM.

图 2 RBM 示意图

假设可见层与隐含层均为二值变量, 可见层与隐含层的神经元数目分别为  $I$  和  $J$ ,  $v_i$  和  $h_j$  分别表示第  $i$  个可见层神经元与第  $j$  个隐含层神经元的状态。对于一组特定的  $(v, h)$ , RBM 作为一个系统所具备的能量定义为

$$E(v, h | \theta) = -\sum_{i=1}^I a_i v_i - \sum_{j=1}^J b_j h_j - \sum_{i=1}^I \sum_{j=1}^J w_{ij} v_i h_j, \quad (1)$$

其中,  $\theta = (w_{ij}, a_i, b_j)$  是 RBM 的参数,  $w_{ij}$  表示可见层节点  $v_i$  与隐含层节点  $h_j$  之间的连接权值,  $a_i$  和  $b_j$  分别表示  $v_i$  和  $h_j$  的偏置值 (bias)。基于该能量函数, 可得到  $(v, h)$  的联合概率分布:

$$p(v, h | \theta) = e^{-E(v, h | \theta)} / Z(\theta), \quad (2)$$

其中,  $Z(\theta) = \sum_v \sum_h e^{-E(v, h | \theta)}$  为归一化项 (也称配分函数)。在实际问题中, 我们最关心的是 RBM 所定义的关于观测变量的分布 (似然函数) 即  $p(v | \theta)$ , 它是联合概率  $p(v, h | \theta)$  的边缘分布。

由于 RBM 的特殊结构 (层内神经元无连接),

当给定可见层节点的状态时, 各个隐含层节点的激活状态之间是相互独立的。此时, 第  $j$  个隐含层节点的激活概率为

$$p(h_j = 1 | v, \theta) = \sigma(b_j + \sum_{i=1}^I v_i w_{ji}), \quad (3)$$

其中,  $\sigma(x) = 1/(1 + e^{-x})$  为 sigmoid 函数。类似的, 给定隐含层节点的状态, 第  $i$  个可见层节点的激活概率为

$$p(v_i = 1 | h, \theta) = \sigma(a_i + \sum_{j=1}^J h_j w_{ji}). \quad (4)$$

RBM 采用迭代的方式进行训练, 训练的目标在于学习出参数  $\theta = (w_{ij}, a_i, b_j)$  的值, 以拟合给定的训练数据。参数  $\theta$  可以通过求在训练集 (设样本数目为  $T$ ) 上的极大对数似然函数得到, 即

$$\theta^* = \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \sum_{t=1}^T \ln p(v^{(t)} | \theta). \quad (5)$$

采用 Hinton 提出的对比散度 (contrastive divergence, CD) 算法<sup>[22]</sup>, 可得各参数的更新规则如下:

$$\Delta w_{ij} = \epsilon (\langle v_i h_j \rangle_{\text{data}} - \langle v_i h_j \rangle_{\text{recon}}); \quad (6)$$

$$\Delta a_i = \epsilon (\langle v_i \rangle_{\text{data}} - \langle v_i \rangle_{\text{recon}}); \quad (7)$$

$$\Delta b_j = \epsilon (\langle h_j \rangle_{\text{data}} - \langle h_j \rangle_{\text{recon}}); \quad (8)$$

其中,  $\epsilon$  为 pre-training 的学习率,  $\langle \cdot \rangle_{\text{data}}$  为训练数据集所定义的分布之上的数学期望,  $\langle \cdot \rangle_{\text{recon}}$  为重构后的模型所定义的分布上的期望。

### 1.2 BP 网络

BP 网络是一种有监督的分类器, 对 RBM 通过 pre-training 得到的特征向量进行分类, 并且起到微调整整个 DBN 网络参数的作用。BP 网络的训练分为前向传播和后向传播两个主要过程。前向传播过程中, 输入特征向量被逐层传播到输出层, 得到预测的分类类别。将实际得到的分类结果与期望的类别数值进行比较得到误差, 该误差被逐层向后回传从而微调 DBN 的参数。后向传播过程中, 需要计算每一层的  $\delta$  (灵敏度) 数值,  $\delta$  被自顶向下传递以修正网络的权值参数。

对于输出层, 假设第  $i$  个节点的实际输出为  $o_i$ , 期望输出为  $d_i$ , 那么灵敏度  $\delta$  的计算表达式为

$$\delta_i = o_i(1 - o_i)(d_i - o_i). \quad (9)$$

对于第  $l$  个隐含层,  $\delta$  的计算表达式为

$$\delta_i^l = y_i^l(1 - y_i^l) \sum_j w_{ij}^l \delta_j^{l+1}. \quad (10)$$

得到各层的  $\delta$  之后, DBN 的网络权值根据式

(11)(12)进行更新:

$$w_{ij}^l = w_{ij}^l + \epsilon_{\text{fine-tuning}} \times y_i^l \delta_j^{l+1}; \quad (11)$$

$$b_j^l = b_j^l + \epsilon_{\text{fine-tuning}} \times \delta_j^{l+1}. \quad (12)$$

## 2 基于 DBN 的遥感图像分类方法

为更好地理解本文提出方法的处理流程,我们给出了如图 3 所示的流程图。为消除遥感图像的斑点(speckle)噪声,对于一幅图像上的每一个要分类的像素,需考虑包括其周围邻居像素点的一片区域。假设邻域窗口大小为  $winsize$ ,可将其展开维度为  $winsize \times winsize$  的一维向量。对于 DBN,其输入数据是经过处理的 Pauli 参数,即相关矩阵(coherency matrix)的对角线元素( $0.5|\mathbf{HH}+\mathbf{VV}|^2$ ,  $0.5|\mathbf{HH}-\mathbf{VV}|^2$  和  $2|\mathbf{HV}|^2$ )。这 3 个不同的 Pauli 参数可拼装为 1 d 的数据向量,因此,对于  $m$  天的数据,输入向量的维度为  $winsize \times winsize \times 3 \times m$ 。

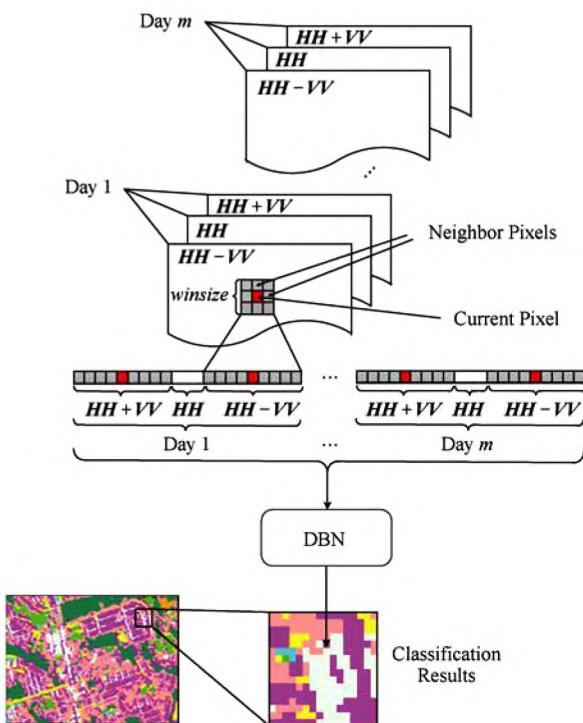


Fig. 3 Flowchart of the DBN-based classification approach.

图 3 基于 DBN 模型的分类方法流程图

在训练过程中,训练样本的 Pauli 参数组成的向量作为输入被送到第 1 层 RBM 的可见层,随后,通过逐层训练的方式,数据在时间和空间上的相关性被依次映射到隐含层  $\mathbf{h}^{(1)}, \mathbf{h}^{(2)}, \dots, \mathbf{h}^{(n-1)}$  及  $\mathbf{h}^{(n)}$  中。为加快训练过程,一般采用批训练(batch learning)

的方式,即每次随机采样固定数目的训练样本作为一个 mini-batch 输入到神经网络,每个 mini-batch 进行一次权值更新。

预测过程中,测试样本的数据用训练样本类似的数据组织方式获得,因而具有相同的数据维度。在已训练的网络结构基础上,通过前向传播计算得到分类的类别。

## 3 实验与分析

### 3.1 实验数据与实验设置

研究区域位于加拿大的多伦多地区,该地区土地覆盖和土地利用的主要类型包括高密度住宅区(HD)、低密度住宅区(LD)、工业和商业区(Ind)、建设工地(Cons)、水域(Water)、森林(Forest)、草地(Pasture)、高尔夫球场(Golf)以及 2 种农作物(Crop1, Crop2)。

我们使用了 6 d 的 RADARSAT-2 卫星遥感图像,其中 4 d(2008-06-11, 2008-07-05, 2008-08-22, 2008-09-15)为上升轨道图像,2 d(2008-06-19, 2008-08-06)为下降轨道的图像。在分类方案中,根据电磁波散射性质的不同,10 个已定义的地表覆盖类型又被细分为共 19 个子类。在训练过程中,每个子类都有约 1 000 个训练样本。共有 4 952 065 个像素点被分类,120 617 个已知类别的像素点被均匀地选取用以验证分类的正确性。

### 3.2 分类精度评价

分类精度分析是遥感分类技术中一个必不可少的环节,通过精度分析可定量判断分类模型的准确性。在遥感分类精度评价中,最常用的方法是利用混淆矩阵进行分析。混淆矩阵(confusion matrix)也称误差矩阵,它反映了分类结果与地表真实类别的相关信息,是分析总体精度和 Kappa 系数等指标的基础。以  $\mathbf{M}$  表示混淆矩阵,其元素  $m_{ij}$  表示测试样本中应属于类别  $j$  而实际被分到类别  $i$  的像素总数。混淆矩阵对角线的元素  $m_{ii}$  的值越大,分类精度越高。

#### 1) 总体精度

总体精度(overall accuracy, OA)是对分类结果质量的总体评价,等于被正确分类的像素总和除以总的像素个数。被正确分类的像素沿着混淆矩阵的对角线分布,它显示了被正确分类到真实分类中的像元数。根据混淆矩阵可得 OA 的计算式为

$$p = \sum_{i=1}^c m_{ii}/N, \quad (13)$$

其中,  $c$  表示类别数目,  $m_{ii}$  表示混淆矩阵对角线上的元素,  $N = \sum_{i=1}^c \sum_{j=1}^c m_{ij}$  表示测试样本的总数.

### 2) Kappa 系数

Kappa 系数<sup>[23]</sup>采用一种多元离散分析技术, 来反映分类结果与参考数据之间的吻合程度, 它考虑了混淆矩阵的所有因子, 是一种更为客观的评价指标, 其定义为

$$k = \frac{N \sum_{i=1}^c m_{ii} - \sum_{i=1}^c (m_{i+} m_{+i})}{N^2 - \sum_{i=1}^c (m_{i+} m_{+i})}, \quad (14)$$

其中,  $m_{i+}, m_{+i}$  分别表示混淆矩阵的第  $i$  行的总和、第  $i$  列的总和. Kappa 系数越大分类精度越高.

## 3.3 结果分析

本节我们主要讨论两方面的内容, 一是 DBN 的结构(包括层数和隐含层节点数)对遥感图像分类效果的影响, 二是 DBN 方法与其他两种分类方法(SVM 和传统神经网络)的比较.

在实验中, 每个像素选取的邻域窗口大小为  $3 \times 3$ , 因此输入数据的维度为 162. 目前, 关于 DBN 结构选取目前尚没有完善的理论依据, 我们通过实验方法确定较优的网络结构. 为简便起见, 我们假设各隐含层具有相同数目的节点. DBN 的层数(不含 BP 层)从 {1, 2, 3, 4, 5, 6} 中选取, 而隐含层节点数目从 {16, 32, 64, 128, 256} 中选取. 根据文献[21, 24]推荐的参数范围并采用网格搜索(grid search)寻优的方法, 我们设置 DBN 的其他参数如下: pre-training 和 fine-tuning 的学习率均为 0.05, mini-batch 大小为 100. 由于样本进行 20 遍迭代之后分类准确率趋于稳定, 我们将样本迭代遍数(epoch)均设置为 20 遍. 对于层数与隐含层节点数的不同组合, 我们通过实验发现, 当 DBN 的层数为 3 层、各隐含层节点数为 64 时, 总体分类精度最高. 下面, 我们采用固定其他参数而变化一种参数的方法来讨论不同网络深度以及隐含层节点数对分类效果的影响.

### 1) 网络深度的影响

对于深度学习模型, 网络深度对分类效果起到十分重要的作用. 一方面, 文献[25]证明了增加 RBM 的层数可以增强 DBN 的建模能力, 更高层的表示有望发掘出更为抽象的特征表示, 提高分类性能. 另一方面, 文献[26]说明了过多的层数可能导致

降低 DBN 的泛化性能, 容易导致过拟合(overfitting)现象. 因此, 合适的 DBN 层数往往与具体的应用和数据集相关.

本实验中, 我们设置每个隐含层的节点数均为 64, 而 DBN 的层数从 1 变化至 6, 结果如图 4 所示. 由图 4 可知, 当 DBN 层数为 3 时, 总体精度(OA)和 Kappa 系数最大.

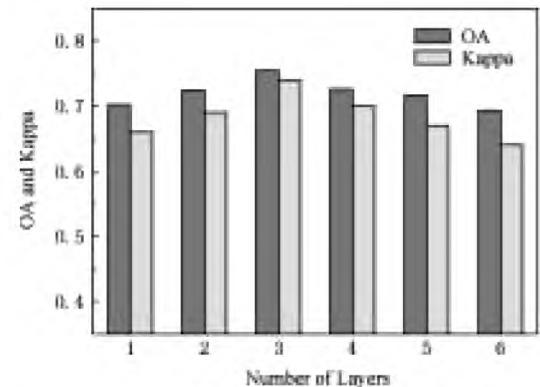


Fig. 4 Effect of different number of layers of DBN.

图 4 DBN 层数对分类效果的影响

### 2) 隐含层节点数的影响

文献[26]指出, 当隐含层节点规模过小, 神经元之间的连接相应较少, 可能不足以提取与分类任务的相关信息; 而神经元数目过多也同样容易导致过拟合的问题. 本实验中我们设定 DBN 层数为 3 层, 其他参数固定, 只改变各层中的隐含层节点数, 结果如图 5 所示. 容易看出, 当各层隐含层节点数取值为 64 时, 总体精度(OA)和 Kappa 系数最大.

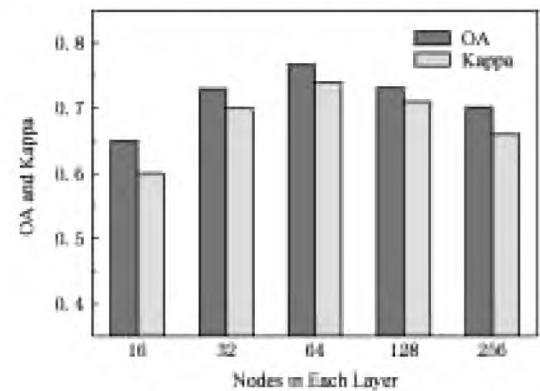


Fig. 5 Effect of different number of nodes in each layer.

图 5 DBN 隐含层节点数对分类效果的影响

### 3) 与其他分类方法的比较

我们将基于 DBN 模型的方法与 SVM 及传统神经网络(NN)两种分类方法进行了对比. SVM 采用常用的开源工具 LIBSVM<sup>[27]</sup>, 其核函数采用径向

基函数(radial basis function, RBF), 惩罚因子 C 和核函数参数 g(gamma)采用网格搜索交叉验证进行寻优. C 的搜索范围分别为 $[2^{-5}, 2^{-3}, \dots, 2^{15}]$ , g 的搜索范围为 $[2^{-15}, 2^{-13}, \dots, 2^3]$ , 共 $11 \times 10 = 110$  种可能组合. 通过 5 折交叉验证(5-fold cross validation), 我们发现当  $C=2^{-3}$ ,  $g=2^{-5}$  时, 可得到最高的交叉验证准确率, SVM 的训练过程即采用此数值. NN 采用常用的 BP 优化方式, 参数与 DBN 类似, 不同之处在于没有多层 RBM 的 pre-training 过程.

几种分类方法的对比实验结果如表 1 所示. 可以看出, 和 SVM 方法相比, DBN 在各个类别和总体分类精度上略有提升. 和 NN 方法相比, DBN 方法在 Water, Golf, HD 几个类别分类精度相当, 而 Pasture 和 Ind 两个类别精度略有提高. 由于 Cons 类别与 Crop2 的混淆增加, 采用 DBN 方法的 Cons 分类精度较 NN 略有下降. 但由于 LD, Crop1, Crop2, Forest 几个类的分类精度有大幅度的提高, DBN 方法的总体分类精度提高了 8%, Kappa 系数提高了

0.09. 总的来看, DBN 方法的分类效果在三者中为最优. 表 2 给出了 DBN 方法分类结果的混淆矩阵.

**Table 1 Comparison of Different Classification Methods**

**表 1 不同分类方法分类效果比较**

Class	SVM	NN	DBN
Water	0.91	0.92	0.92
Golf	0.80	0.84	0.84
Pasture	0.74	0.74	0.76
Cons	0.83	0.88	0.86
LD	0.46	0.34	0.47
Crop1	0.82	0.75	0.84
Crop2	0.90	0.84	0.91
Forest	0.76	0.52	0.79
HD	0.70	0.71	0.71
Ind	0.70	0.71	0.75
OA	0.75	0.69	0.77
Kappa	0.71	0.65	0.74

**Table 2 Confusion Matrix of DBN Classification Results**

**表 2 DBN 分类结果的混淆矩阵**

Class	Ground-truth										Total
	Water	Golf	Pasture	Cons	LD	Crop1	Crop2	Forest	HD	Ind	
Water	4 825	206	0	1	0	0	0	0	0	0	5 032
Golf	353	6 771	1 144	172	190	14	10	125	32	139	8 950
Pasture	0	431	10 215	55	227	582	189	415	23	0	12 137
Cons	56	529	409	5 830	8	31	491	24	21	44	7 443
LD	0	35	180	87	7 121	231	97	720	1 122	340	9 933
Crop1	0	13	523	85	430	8 164	140	191	116	49	9 711
Crop2	0	10	356	384	155	129	15 819	267	27	10	17 157
Forest	0	14	458	30	1 199	206	509	12 639	97	69	15 221
HD	0	24	194	52	4 342	396	169	1 427	9 159	3 333	19 096
Ind	0	11	1	84	1 481	0	0	113	2 300	11 947	15 937
Total	5 234	8 044	13 480	6 780	15 153	9 753	17 424	15 921	12 897	15 931	120 617
Accuracy/%	92.19	84.17	75.78	85.99	46.99	83.71	90.79	79.39	71.02	74.99	100.00

DBN 分类效果提升的原因在于, DBN 的各层 RBM 通过 pre-training 的无监督学习为神经网络的权值提供了更为合适的初始值, 而不是像普通神经网络那样给权值赋以随机数. 因此, DBN 结合了无监督学习和有监督学习各自的优点, 能更好地发掘遥感数据在时间上和空间上的规律性, 进而提高分

类精度.

图 6 显示了一个 LD 区域几种分类方法的分类结果, 可见, 与 NN 方法相比, DBN 方法减少了 LD 类别被错分为 HD 类别. 图 7 显示了一个地物种类较多的较大区域的分类结果, 与 NN 相比较, DBN 方法较好地保留了地物类别的细节, 并且 Forest 类

别被错分为 HD 的情况较少。

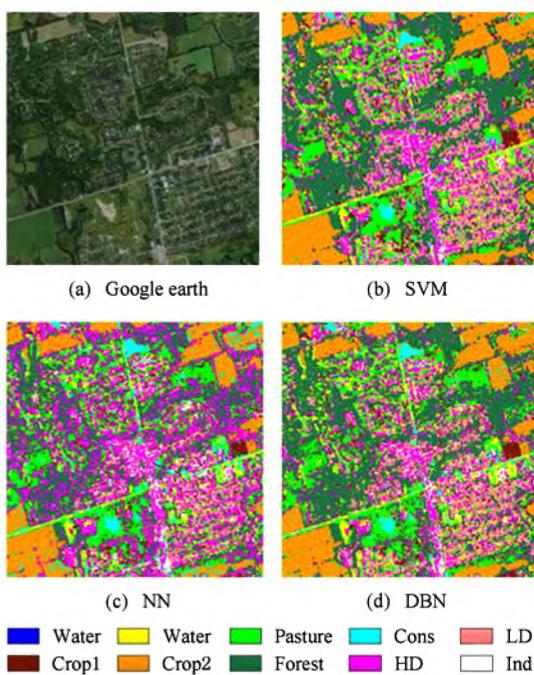


Fig. 6 Comparison of classification results in an LD area.

图 6 一个 LD 区域分类效果比较示意图

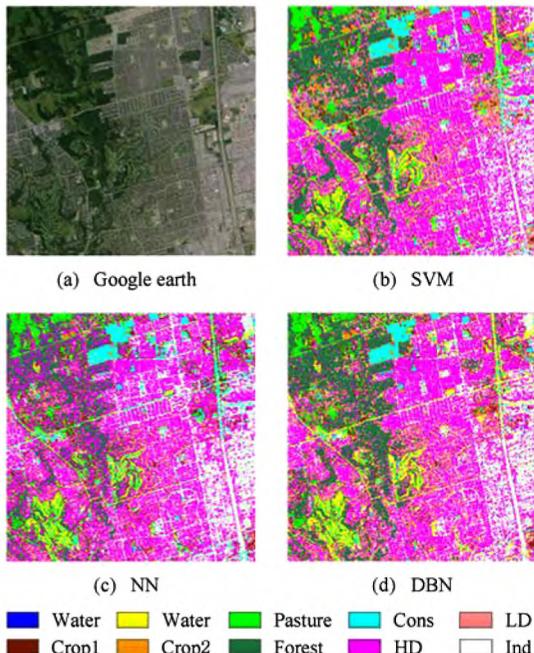


Fig. 7 Comparison of land cover classification results in selected area.

图 7 一个较大区域分类效果比较示意图

## 4 总 结

本文提出了一种基于深度学习结构——DBN

模型的遥感 SAR 图像的分类方法。DBN 结合了无监督学习和有监督学习的优点,可自动发掘遥感数据在时间和空间上所蕴含的规律,进而提高分类的准确性。实验表明,该方法可取得优于 SVM 及传统神经网络(NN)的分类效果。在下一步工作中,我们将更深入研究多种深度学习模型,以进一步提高遥感图像分类的准确度。

## 参 考 文 献

- [1] Moreira A, Iraola P, Younis M, et al. A tutorial on synthetic aperture radar [J]. IEEE Geoscience and Remote Sensing Magazine, 2013, 1(1): 6–43
- [2] Lombardo P, Sciotti M, Pellizzeri T M, et al. Optimum model-based segmentation techniques for multifrequency polarimetric SAR images of urban areas [J]. IEEE Trans on Geoscience and Remote Sensing, 2003, 41(9): 1959–1975
- [3] Alberga V. A study of land cover classification using polarimetric SAR parameters [J]. Int Journal of Remote Sensing, 2007, 28(17): 3851–3870
- [4] Hagner O, Reese H. A method for calibrated maximum likelihood classification of forest types [J]. Remote Sensing of Environment, 2007, 110(4): 438–444
- [5] Khan K U, Yang J, Zhang W. Unsupervised classification of polarimetric SAR images by EM algorithm [J]. IEICE Trans on Communications, 2007, E90-B(12): 3632–3642
- [6] Heermann P, Khazenie N. Classification of multispectral remote sensing data using a back-propagation neural network [J]. IEEE Trans on Geoscience and Remote Sensing, 1992, 30(1): 81–88
- [7] Pal M, Mather P M. An assessment of the effectiveness of decision tree methods for land cover classification [J]. Remote Sensing of Environment, 2003, 86(4): 1145–1161
- [8] Lardeux C, Frison P, Tison C, et al. Support vector machine for multifrequency SAR polarimetric data classification [J]. IEEE Trans on Geoscience and Remote Sensing, 2009, 47(12): 4143–4152
- [9] Niu X, Ban Y F. Multi-temporal RADARSAT-2 polarimetric SAR data for urban land-cover classification using an object-based support vector machine and a rule-based approach [J]. Int Journal of Remote Sensing, 2013, 34(1): 1–26
- [10] Niu X, Ban Y F. A novel contextual classification algorithm for multitemporal polarimetric SAR data [J]. IEEE Geoscience and Remote Sensing Letters, 2014, 11(3): 681–685
- [11] Hinton G E, Salakhutdinov R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313 (5786): 504–507
- [12] Yu D, Deng L. Deep learning and its applications to signal and information processing [J]. IEEE Signal Processing Magazine, 2011, 28(1): 145–154

- [13] Arel I, Rose C, Karnowski T. Deep machine learning—A new frontier in artificial intelligence [J]. IEEE Computational Intelligence Magazine, 2010, 5(4): 13–18
- [14] Bengio Y. Learning deep architectures for AI [J]. Foundation and Trends in Machine Learning, 2009, 2(1): 1–127
- [15] Bengio Y, Courville A, Vincent P. Representation learning: A review and new perspectives [J]. IEEE Trans on Pattern Analysis and Machine Intelligence, 2013, 35(8): 1798–1828
- [16] Anthes G. Deep learning comes of age [J]. Communications of the ACM, 2013, 56(6): 13–15
- [17] Jones N. The learning machines [J]. Nature, 2014, 505 (7482): 146–148
- [18] Hu Xiaolin, Zhu Jun. Deep learning: New hotspot in machine learning [J]. Communications of the CCF, 2013, 9 (7): 64–69 (in Chinese)  
(胡晓林, 朱军. 深度学习: 机器学习领域的热点 [J]. 中国计算机学会通讯, 2013, 9(7): 64–69)
- [19] Yu Kai, Jia Lei, Chen Yuqiang, et al. Deep learning: Yesterday, today, and tomorrow [J]. Journal of Computer Research and Development, 2013, 50(9): 1799–1804 (in Chinese)  
(余凯, 贾磊, 陈雨强, 等. 深度学习的昨天、今天和明天 [J]. 计算机研究与发展, 2013, 50(9): 1799–1804)
- [20] Mnih V, Hinton G E. Learning to detect roads in high resolution aerial images [C] //Proc of 2010 European Conf Computer Vision (ECCV2010). Piscataway, NJ: IEEE, 2010: 210–223
- [21] Hinton G E, Osindero S, Teh Y. A fast learning algorithm for deep belief nets [J]. Neural Computation, 2006, 18(7): 1527–1554
- [22] Hinton G E. Training products of experts by minimizing contrastive divergence [J]. Neural Computation, 2002, 14 (8): 1771–1800
- [23] Luo Xiaobo, Zhao Chunhui, Pan Jianping, et al. Remote Sensing Image Intelligent Classification and Its Application [M]. Beijing: Publishing House of Electronics Industry, 2011 (in Chinese)  
(罗小波, 赵春晖, 潘建平, 等. 遥感图像智能分类及其应用 [M]. 北京: 电子工业出版社, 2011)
- [24] Hinton G E. A practical guide to training restricted Boltzmann machines, UTML TR 2010-003 [R]. Toronto: Department of Computer Science, University of Toronto, 2010
- [25] Roux N, Bengio Y. Representational power of restricted Boltzmann machines and deep belief networks [J]. Neural Computation, 2008, 20(7): 1631–1649
- [26] Larochelle H, Bengio Y, Louradour J, et al. Exploring strategies for training deep neural networks [J]. Journal of Machine Learning Research, 2009, 10(1): 1–40
- [27] Lin C J. LIBSVM: A library for support vector machines [OL]. [2013-11-12]. <http://www.csie.ntu.edu.tw/~cjlin/libsvm/>



**Lü Qi**, born in 1987. PhD candidate. Student member of China Computer Federation. His research interests include computer architecture, machine learning and remote sensing image processing.



**Dou Yong**, born in 1966. Professor and PhD supervisor. Senior member of China Computer Federation. His research interests include computer architecture and reconfigurable computing.



**Niu Xin**, born in 1983. Received his PhD degree from Royal Institute of Technology (KTH), Sweden in 2012. His research interests include computer architecture, machine learning, pattern recognition and remote sensing image processing.



**Xu Jiaqing**, born in 1982. Received his PhD degree from National University of Defense Technology in 2012. His research interests include computer architecture and bio-inspired computing.



**Xia Fei**, born in 1980. Received his PhD degree from National University of Defense Technology in 2011. His research interests include computer architecture, bioinformatics and signal processing.

# 基于DBN模型的遥感图像分类

作者: 吕启, 窦勇, 牛新, 徐佳庆, 夏飞, Lü Qi, Dou Yong, Niu Xin, Xu Jiaqing, Xia Fei  
作者单位: 吕启, 窦勇, 牛新, 徐佳庆, Lü Qi, Dou Yong, Niu Xin, Xu Jiaqing(国防科学技术大学计算机学院并行与分布处理国防科技重点实验室 长沙 410073), 夏飞, Xia Fei(海军工程大学电子工程学院 武汉 430033)  
刊名: 计算机研究与发展     
英文刊名: Journal of Computer Research and Development  
年, 卷(期): 2014, 51(9)

引用本文格式: 吕启, 窦勇, 牛新, 徐佳庆, 夏飞, Lü Qi, Dou Yong, Niu Xin, Xu Jiaqing, Xia Fei 基于DBN模型的遥感图像分类[期刊论文]-计算机研究与发展 2014(9)